

IFLCE015 Apprentissage profond pour la vision

Détection de masques faciaux par Faster R-CNN

Étudiant : Fallou Diouf

Professeur : Pr Sylvain Lobry

1 Introduction

Ce travail porte sur la détection automatique du port du masque facial à partir d'images. Le jeu de données contient trois classes : `with_mask`, `without_mask` et `mask_wearred_incorrect`. Les annotations sont fournies sous forme de fichiers XML contenant les classes et les coordonnées des boîtes englobantes. Un modèle Faster R-CNN pré-entraîné sur COCO est adapté à cette tâche.

2 Données et annotations

Le jeu de données contient 853 images et 853 fichiers XML.

Réponse 1 – Structure des annotations. Chaque fichier XML contient les objets présents dans l'image, leur nom de classe et leur boîte englobante. Les coordonnées sont données sous la forme $[x_{\min}, y_{\min}, x_{\max}, y_{\max}]$, avec $(x_{\min}, y_{\min})$ en haut à gauche et $(x_{\max}, y_{\max})$ en bas à droite. Par exemple, `makssssksksss0.xml` contient trois objets avec les boîtes $[79, 105, 109, 142]$, $[185, 100, 226, 144]$ et $[325, 90, 360, 141]$.

Réponse 2 – Sources de biais. Plusieurs biais potentiels peuvent être présents : déséquilibre entre les classes, différences de luminosité et de qualité d'image, arrière-plans variés, tailles et orientations différentes des visages. Le modèle peut ainsi apprendre certaines caractéristiques propres au jeu de données en plus des caractéristiques liées au masque.

3 Préparation des données

Réponse 3 – Découpage du jeu de données. Les 853 images ont été divisées aléatoirement en 511 images d'entraînement, 171 de validation et 171 de test, soit environ 60 %, 20 % et 20 %. Pour un jeu de données de cette taille, l'augmentation des données, la validation croisée et le transfert d'apprentissage constituent des stratégies permettant d'améliorer la généralisation.

Réponse 4 – Répartition des classes. Le comptage des objets annotés donne :

Classe	Nombre
<code>with_mask</code>	3232
<code>without_mask</code>	717
<code>mask_wearred_incorrect</code>	123
Total	4072

La classe `with_mask` représente 79.4 % des objets, `without_mask` 17.6 % et `mask_wearred_incorrect` seulement 3.0 %. Le jeu de données est donc fortement déséquilibré.

4 Modèle et entraînement

Le modèle utilisé est un Faster R-CNN avec un backbone ResNet-50 et une Feature Pyramid Network (FPN), pré-entraîné sur COCO. Sa tête de classification a été remplacée pour produire quatre classes : les trois classes du problème et la classe *background*. Les images sont converties en tenseurs et les annotations sont fournies sous forme de boîtes et d'indices de classes. Une fonction *collate* permet de gérer le nombre variable d'objets par image.

Réponse 5 – Hyperparamètres. L'entraînement utilise SGD avec un taux d'apprentissage de 0.001, un momentum de 0.01, une taille de batch de 2 et 5 époques. Ces valeurs constituent des paramètres initiaux d'expérimentation et n'ont pas été obtenues par une recherche systématique.

5 Résultats et analyse

La figure 1 montre l'évolution des losses. La loss d'entraînement diminue de 0.3199 à 0.1761 et la loss de validation de 0.3017 à 0.2072. Les deux courbes diminuent pendant les cinq époques : aucune remontée de la validation loss n'est observée, ce qui ne permet pas de conclure à un surapprentissage à partir de ces seules courbes.




FIGURE 1 – Évolution des losses d'entraînement et de validation.

Sur l'ensemble de test, composé de 171 images, la loss est de 0.1860. Les prédictions sont évaluées avec un seuil de confiance de 0.5 et un seuil d'IoU de 0.5 pour la correspondance entre boîtes prédites et annotations.

Classe	Precision	Recall	F1
with_mask	0.8013	0.8386	0.8195
without_mask	0.6824	0.3671	0.4774
mask_wearred_incorrect	0.0000	0.0000	0.0000
Global	0.7894	0.7317	0.7595

Les performances varient fortement selon les classes. La classe **with_mask**, majoritaire, obtient un F1-score de 0.8195. Le rappel de **without_mask** est plus faible (0.3671). La classe **mask_wearred_incorrect** n'est correctement détectée dans aucun cas de l'évaluation. Ce résultat est cohérent avec son très faible nombre d'exemples : seulement 123 objets contre 3232 pour **with_mask**. Les visualisations montrent également des prédictions correctes sur plusieurs visages ainsi que des confusions, notamment entre **with_mask** et les autres classes.

6 Conclusion

Ce travail a permis de mettre en place une chaîne complète de détection d’objets, depuis l’exploitation des annotations XML jusqu’à l’évaluation d’un Faster R-CNN. L’entraînement pendant cinq époques réduit les losses d’entraînement et de validation. Sur le test, le modèle obtient une précision globale de 0.7894, un rappel de 0.7317 et un F1-score de 0.7595. Les résultats montrent toutefois l’impact du déséquilibre des classes, particulièrement pour `mask_wearied_incorrect`. Des données supplémentaires pour les classes minoritaires, de l’augmentation de données et une recherche d’hyperparamètres pourraient être étudiées pour améliorer les performances.

6.1 Analyse qualitative

Les visualisations permettent de comparer les annotations réelles (*Ground Truth*) aux prédictions du modèle. Plusieurs visages sont correctement localisés et classifiés, notamment pour la classe `with_mask`. Les scores de confiance sont généralement élevés pour ces détections.

Cependant, certaines erreurs sont observées. Le modèle confond notamment certaines personnes sans masque avec la classe `with_mask`. La classe `mask_wearied_incorrect` constitue la principale difficulté, ce qui est cohérent avec son faible nombre d’exemples dans le jeu de données.



FIGURE 2 – Exemples de prédictions du modèle : annotations réelles en vert et prédictions en rouge.